# Analisis Perbandingan Implementasi Retrieval-Augmented Generation (RAG) pada GPT-4o dan Gemini 1.5 Pro dalam Meningkatkan Performa Sistem NLP

**Disusun oleh:**
Shanaya Balghis Riyona 241552010012
Thoriqurrahman Akrami 241552010014

**Dosen Pengampu:**
Hendri Karisma, S.Kom., M.Kom

**Program Studi Teknik Infomatika, Sekolah Tinggi Manajemen Informatika Komputer Tazkia**
**Jl. Raya Dramaga Blok Radar Baru No.8, RT.03/RW.03, Margajaya, Kota Bogor, Jawa Barat 16116, Indonesia**

**2026**

# BAB I
# PENDAHULUAN

## 1.1 Latar Belakang

Perkembangan Artificial Intelligence (AI), khususnya dalam bidang Natural Language Processing (NLP), telah mengalami peningkatan yang sangat signifikan dalam beberapa tahun terakhir. Salah satu teknologi yang paling menonjol adalah Large Language Model (LLM), yaitu model kecerdasan buatan yang mampu memahami, memproses, dan menghasilkan teks secara otomatis dengan kualitas yang semakin mendekati bahasa manusia. Contoh model LLM yang banyak digunakan saat ini adalah GPT-4o dan Gemini 1.5 Pro, yang telah dimanfaatkan dalam berbagai aplikasi seperti chatbot, asisten virtual, pencarian informasi, hingga pembuatan konten digital.

Meskipun memiliki kemampuan yang canggih, model LLM masih memiliki beberapa keterbatasan, seperti hallucination, yaitu kondisi ketika model menghasilkan informasi yang tampak meyakinkan tetapi tidak sesuai fakta, serta kurangnya akurasi dalam menjawab pertanyaan yang membutuhkan data spesifik atau terbaru. Permasalahan tersebut menjadi tantangan penting dalam pengembangan sistem NLP modern.

Untuk mengatasi kendala tersebut, dikembangkan metode Retrieval-Augmented Generation (RAG), yaitu pendekatan yang menggabungkan proses pencarian informasi (*retrieval*) dari sumber eksternal dengan kemampuan generatif model bahasa. Dengan metode ini, model dapat mengakses informasi tambahan yang relevan sebelum menghasilkan jawaban, sehingga mampu meningkatkan akurasi, relevansi, dan keandalan respons [1].

Seiring berkembangnya teknologi AI, muncul pendekatan lanjutan yaitu Stochastic RAG, yang menawarkan mekanisme retrieval berbasis probabilistik dan optimasi secara end-to-end. Pendekatan ini dinilai mampu meningkatkan performa model secara keseluruhan, terutama dalam memilih informasi yang paling relevan dan menghasilkan jawaban yang lebih optimal [2].

Oleh karena itu, diperlukan analisis perbandingan terhadap implementasi metode RAG pada model GPT-4o dan Gemini 1.5 Pro untuk mengetahui kelebihan, kekurangan, serta efektivitas masing-masing model dalam meningkatkan performa sistem NLP modern.

## 1.2 Rumusan Masalah

1. Apa yang dimaksud dengan model GPT-4o dan Gemini 1.5 Pro sebagai Large Language Model (LLM) modern?
2. Bagaimana penerapan metode Retrieval-Augmented Generation (RAG) pada GPT-4o dan Gemini 1.5 Pro dalam sistem Natural Language Processing (NLP)?
3. Apa kelebihan dan kekurangan masing-masing model dalam meningkatkan akurasi, relevansi, dan efisiensi jawaban?
4. Bagaimana perbandingan performa antara GPT-4o dan Gemini 1.5 Pro berbasis RAG?

## 1.3 Tujuan

1. Memahami konsep dan karakteristik model GPT-4o dan Gemini 1.5 Pro sebagai model AI modern.
2. Mengetahui penerapan metode Retrieval-Augmented Generation (RAG) pada kedua model.
3. Menganalisis kelebihan dan kekurangan masing-masing model dalam sistem NLP.
4. Membandingkan performa GPT-4o dan Gemini 1.5 Pro berbasis RAG dalam meningkatkan kualitas respons.

# BAB II
# PEMBAHASAN

## 2.1 Retrieval-Augmented Generation (RAG)

Retrieval-Augmented Generation (RAG) merupakan metode yang menggabungkan dua komponen utama, yaitu proses retrieval untuk mengambil informasi dari sumber eksternal seperti database, dokumen, atau knowledge base, serta proses generation untuk menghasilkan jawaban menggunakan model bahasa besar seperti GPT-4o dan Gemini 1.5 Pro.

Dalam metode ini, sistem tidak hanya mengandalkan pengetahuan bawaan dari model yang diperoleh saat pelatihan, tetapi juga melakukan pencarian informasi yang relevan secara real-time sebelum menyusun jawaban. Dengan demikian, model dapat memberikan respons yang lebih akurat, relevan, dan sesuai konteks pengguna [1].

Cara Kerja RAG adalah sebagai berikut:

1. Sistem menerima pertanyaan atau perintah dari pengguna.
2. Sistem melakukan pencarian informasi yang relevan pada database atau dokumen eksternal.
3. Informasi yang ditemukan dipilih dan dijadikan konteks tambahan.
4. Model bahasa seperti GPT-4o atau Gemini 1.5 Pro memproses konteks tersebut.
5. Model menghasilkan jawaban yang lebih tepat dan informatif.

Metode RAG banyak digunakan dalam berbagai sistem modern, seperti chatbot cerdas, mesin pencari berbasis AI, layanan customer service otomatis, sistem tanya jawab, dan asisten virtual perusahaan. Hal ini karena RAG mampu mengurangi risiko hallucination, meningkatkan akurasi informasi, serta memungkinkan model mengakses data terbaru yang tidak terdapat pada data pelatihan awal.

Pada implementasinya, GPT-4o dan Gemini 1.5 Pro sama-sama dapat memanfaatkan metode RAG untuk meningkatkan performa sistem Natural

Language Processing (NLP), terutama dalam memahami pertanyaan kompleks dan menghasilkan jawaban berbasis fakta.

## 2.2 GPT-4o dan Gemini 1.5 Pro sebagai Model AI Berbasis RAG

GPT-4o dan Gemini 1.5 Pro merupakan dua model Large Language Model (LLM) modern yang memiliki kemampuan tinggi dalam memahami bahasa alami, menghasilkan teks, serta mendukung berbagai bentuk input multimodal seperti teks, gambar, dan dokumen. Kedua model ini banyak digunakan dalam berbagai aplikasi AI, seperti chatbot, asisten virtual, pencarian informasi, hingga analisis data.

Dalam meningkatkan kualitas jawaban, kedua model tersebut dapat diintegrasikan dengan metode Retrieval-Augmented Generation (RAG). Melalui pendekatan ini, model tidak hanya mengandalkan pengetahuan internal hasil pelatihan, tetapi juga dapat mengambil informasi tambahan dari sumber eksternal secara real-time. Hal tersebut memungkinkan jawaban yang dihasilkan menjadi lebih akurat, relevan, dan sesuai kebutuhan pengguna.

1. **GPT-4o**

   GPT-4o merupakan model AI yang dikembangkan oleh OpenAI dengan fokus pada kecepatan respons, kemampuan multimodal, serta kualitas generasi bahasa yang tinggi. Dalam implementasi RAG, GPT-4o mampu memanfaatkan dokumen atau basis data eksternal untuk memberikan jawaban yang lebih informatif dan kontekstual.

2. **Gemini 1.5 Pro**

   Gemini 1.5 Pro merupakan model AI yang dikembangkan oleh Google dengan keunggulan pada pemrosesan konteks panjang, integrasi ekosistem Google, dan kemampuan multimodal. Dengan dukungan RAG, Gemini 1.5 Pro dapat mengakses sumber data tambahan untuk meningkatkan kualitas jawaban, terutama pada pencarian informasi berskala besar.

### 2.3 Kelebihan dan Kekurangan GPT-4o dan Gemini 1.5 Pro Berbasis RAG

Dalam implementasi metode Retrieval-Augmented Generation (RAG), model GPT-4o dan Gemini 1.5 Pro memiliki keunggulan serta keterbatasan masing-masing. Perbandingan ini penting untuk mengetahui model mana yang lebih sesuai digunakan pada kebutuhan sistem Natural Language Processing (NLP) tertentu.

**A. GPT-4o**

**Kelebihan:**

- Memiliki kemampuan generasi teks yang sangat natural dan mudah dipahami.
- Mampu memahami instruksi kompleks dan pertanyaan multi-langkah.
- Mendukung input multimodal seperti teks, gambar, dan dokumen.
- Dengan metode RAG, mampu menghasilkan jawaban yang lebih akurat dan relevan.
- Cocok digunakan pada chatbot, asisten virtual, dan pembuatan konten otomatis.

**Kekurangan:**

- Membutuhkan sumber daya komputasi yang cukup besar.
- Jika retrieval tidak optimal, model masih berpotensi menghasilkan hallucination.
- Biaya implementasi relatif lebih tinggi pada skala besar.
- Ketergantungan pada kualitas data eksternal yang digunakan dalam RAG.

**B. Gemini 1.5 Pro**

**Kelebihan:**

- Memiliki kemampuan memahami konteks panjang dengan sangat baik.

- Terintegrasi dengan ekosistem Google seperti Search, Docs, dan Workspace.
- Mendukung kemampuan multimodal dengan performa tinggi.
- Dengan metode RAG, mampu mengakses informasi real-time secara lebih luas.
- Cocok digunakan pada pencarian informasi, analisis dokumen, dan produktivitas digital.

**Kekurangan:**

- Performa jawaban dapat bergantung pada integrasi sistem retrieval yang digunakan.
- Implementasi lanjutan membutuhkan infrastruktur teknologi yang memadai.
- Pada beberapa kasus, gaya respons kurang natural dibanding GPT-4o.
- Belum semua fitur tersedia merata di berbagai wilayah dan platform.

### 2.4 Perbandingan Model

Perbandingan antara GPT-4o dan Gemini 1.5 Pro berbasis metode Retrieval-Augmented Generation (RAG) dapat dilihat dari beberapa aspek penting, seperti akurasi, kemampuan multimodal, integrasi sistem, kompleksitas implementasi, dan penggunaan di dunia nyata.

| Aspek | GPT-4o | Gemini 1.5 Pro |
|---|---|---|
| Akurasi Jawaban | Sangat tinggi | Sangat tinggi |
| Pemahaman Konteks | Sangat baik | Sangat baik, unggul pada konteks panjang |
| Kemampuan Multimodal | Teks, gambar, audio | Teks, gambar, dokumen |
| Integrasi RAG | Sangat baik | Sangat baik |
| Kecepatan Respons | Cepat | Cepat |
| Kreativitas Generasi Teks | Sangat tinggi | Tinggi |
| Integrasi Ekosistem | OpenAI API dan tools eksternal | Google Search, Docs, Workspace |

| | | |
|---|---|---|
| Kompleksitas Implementasi | Sedang | Sedang hingga tinggi |
| Penggunaan | Chatbot, AI assistant, content creation | Productivity tools, search, enterprise AI |

**2.5 Analisis**

Berdasarkan perbandingan yang telah dilakukan, GPT-4o menunjukkan keunggulan dalam kemampuan menghasilkan teks yang natural, kreatif, dan responsif terhadap berbagai jenis pertanyaan pengguna. Model ini sangat efektif digunakan pada sistem chatbot, asisten virtual, pembuatan konten otomatis, serta aplikasi interaktif lainnya. Selain itu, integrasi metode Retrieval-Augmented Generation (RAG) pada GPT-4o mampu meningkatkan akurasi jawaban dengan memanfaatkan sumber data eksternal yang relevan.

Di sisi lain, Gemini 1.5 Pro memiliki keunggulan dalam memahami konteks panjang, mengolah dokumen berukuran besar, serta terintegrasi dengan ekosistem Google seperti Search, Docs, dan Workspace. Hal ini menjadikan Gemini 1.5 Pro sangat cocok digunakan pada kebutuhan produktivitas digital, pencarian informasi, dan analisis dokumen secara mendalam. Dengan dukungan RAG, model ini mampu memberikan jawaban berbasis data yang lebih luas dan terkini.

Dari segi performa, kedua model sama-sama memiliki kemampuan tinggi dalam sistem Natural Language Processing (NLP). Namun, GPT-4o lebih unggul pada aspek percakapan natural dan kreativitas bahasa, sedangkan Gemini 1.5 Pro lebih unggul pada pengelolaan konteks besar dan integrasi layanan digital.

Oleh karena itu, pemilihan model terbaik bergantung pada kebutuhan pengguna. Jika dibutuhkan interaksi cerdas dan fleksibel, maka GPT-4o menjadi pilihan yang tepat. Sementara itu, jika dibutuhkan pengolahan data besar dan integrasi produktivitas, maka Gemini 1.5 Pro lebih sesuai digunakan.

# BAB III
# PENUTUP

## Kesimpulan

Berdasarkan hasil analisis yang telah dilakukan, dapat disimpulkan bahwa GPT-4o dan Gemini 1.5 Pro merupakan dua model Artificial Intelligence (AI) modern yang memiliki kemampuan tinggi dalam bidang Natural Language Processing (NLP). Kedua model mampu memahami bahasa alami, menghasilkan teks secara otomatis, serta mendukung berbagai bentuk input multimodal seperti teks, gambar, dan dokumen.

Penerapan metode Retrieval-Augmented Generation (RAG) pada kedua model terbukti mampu meningkatkan akurasi jawaban, relevansi informasi, serta mengurangi terjadinya hallucination. Dengan memanfaatkan sumber data eksternal, model dapat memberikan respons yang lebih sesuai dengan kebutuhan pengguna dan data terkini.

Secara umum, GPT-4o lebih unggul dalam kemampuan percakapan natural, kreativitas generasi teks, dan interaksi yang fleksibel. Sementara itu, Gemini 1.5 Pro lebih unggul dalam pemrosesan konteks panjang, analisis dokumen besar, dan integrasi dengan ekosistem Google.

Dengan demikian, pemilihan model terbaik bergantung pada tujuan penggunaan. GPT-4o cocok digunakan untuk chatbot, asisten virtual, dan pembuatan konten, sedangkan Gemini 1.5 Pro lebih sesuai untuk produktivitas digital, pencarian informasi, dan analisis data berskala besar.

# Daftar Pustaka


[1] P. Lewis, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *arXiv,* 2020.

[2] T. Xie, "Stochastic RAG: End-to-End Retrieval-Augmented Generation through Expected Utility Maximization," *arXiv,* 2024.

[3] Y. Gao, "Retrieval-Augmented Generation for Large Language Models: A Survey," *arXiv,* 2023.

[4] Jurnal Ilmu Teknologi Informasi, "Utilizing Retrieval-Augmented Generation in Large Language Models to Enhance Indonesian Language NLP," *Jurnal Ilmu Teknologi Informasi,* 2024.

[5] Jurnal Tekomin, "Implementasi Retrieval-Augmented Generation untuk Evaluasi Proposal Tugas Akhir Mahasiswa," *Jurnal Tekomin,* 2024.

[6] Infomedia Journal, "Retrieval-Augmented Generation (RAG) Chatbot for Handling Customer Complaints in the Energy Sector," *Infomedia Journal,* 2024.

[7] I. Technology, "What is Retrieval-Augmented Generation (RAG)?," 2023. [Online]. Available: https://www.youtube.com/watch?v=T-D1OfcDW1M.