

**Pengembangan RAG Chatbot Berbasis Small Language
Models (SLMs) Menggunakan Ollama: Studi Komparatif
Efisiensi dan Akurasi Model Phi-3-mini, Gemma 2B, dan
LLaMA 3.2**



Disusun oleh:

Shanaya Balghis Riyona 241552010012

Thoriqurrahman Akrami 241552010014

Dosen Pengampu:

Hendri Karisma, S.Kom., M.Kom

**Program Studi Teknik Infomatika, Sekolah Tinggi
Manajemen Informatika Komputer Tazkia
Jl. Raya Dramaga Blok Radar Baru No.8, RT.03/RW.03,
Margajaya, Kota Bogor, Jawa Barat 16116, Indonesia**

2026

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Allah Subhanahu wa Ta'ala atas limpahan rahmat, taufik, dan hidayah-Nya sehingga laporan Tugas Besar 1 (Ujian Tengah Semester) ini dapat diselesaikan tepat pada waktunya. Shalawat serta salam senantiasa tercurah kepada Nabi Muhammad Shallallahu 'Alaihi Wasallam beserta keluarga dan para sahabatnya.

Laporan yang berjudul "**Pengembangan RAG Chatbot Berbasis Small Language Models (SLMs) Menggunakan Ollama: Studi Komparatif Efisiensi dan Akurasi Model Phi-3 dan Gemma 2B**" ini disusun sebagai pemenuhan tugas mata kuliah Artificial Intelligence pada Program Studi Teknik Informatika, STMIK Tazkia. Laporan ini mengkaji perancangan sistem *Retrieval-Augmented Generation* berbasis model bahasa lokal serta membandingkan performa dua model SLM terkini secara empiris.

Dalam proses penyusunan laporan ini, penulis menyadari sepenuhnya bahwa keberhasilannya tidak terlepas dari dukungan dan bimbingan berbagai pihak. Oleh karena itu, penulis menyampaikan rasa terima kasih yang sebesar-besarnya kepada Bapak Hendri Karisma, S.Kom., M.Kom. selaku Dosen Pengampu mata kuliah Generative AI & Large Language Models, atas bimbingan, arahan, dan ilmu yang telah diberikan selama perkuliahan berlangsung.

Penulis menyadari bahwa laporan ini masih jauh dari kesempurnaan, baik dari segi substansi teknis maupun tata penulisan. Oleh karena itu, kritik dan saran yang bersifat konstruktif dari Bapak Dosen dan seluruh pembaca sangat penulis harapkan demi perbaikan ke depan. Demikian laporan ini disusun. Semoga dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya dalam bidang kecerdasan buatan dan pemrosesan bahasa alami.

Bogor, Juni 2026

Penulis,

ABSTRAK

Penelitian ini menyajikan rancang bangun sistem *Retrieval-Augmented Generation* (RAG) berbasis *Small Language Models* (SLMs) yang beroperasi sepenuhnya secara luring (*offline*) menggunakan framework Ollama. Studi komparatif dilaksanakan terhadap tiga model SLM *open-weights* dari vendor berbeda, yaitu Microsoft Phi-3-mini (3,8 miliar parameter), Google Gemma 2B (2 miliar parameter), dan Meta LLaMA 3.2:1B (1 miliar parameter), dengan tujuan mengukur efisiensi komputasi serta kualitas respons yang dihasilkan dalam konteks pipeline RAG.

Sistem dibangun di atas tumpukan teknologi yang terdiri atas Python sebagai bahasa pemrograman utama, LangChain sebagai orkestrator pipeline, ChromaDB sebagai *vector store* persisten, dan model embedding *all-MiniLM-L6-v2* dari HuggingFace Sentence Transformers sebagai mesin representasi semantik. Evaluasi performa mencakup dua dimensi: dimensi kuantitatif yang meliputi *Time to First Token* (TTFT), *Words per Second* (WPS), dan konsumsi memori RAM; serta dimensi kualitatif yang menilai relevansi jawaban, tingkat *faithfulness* terhadap konteks dokumen, dan minimisasi halusinasi.

Guna menjamin konsistensi dan reproduktibilitas eksperimen, seluruh konfigurasi model menerapkan *prompt engineering* deterministik dengan nilai *temperature* sebesar 0,0 hingga 0,1. Dengan membandingkan tiga model dari tiga vendor teknologi terkemuka dunia Microsoft, Google, dan Meta penelitian ini diharapkan menghasilkan panduan empiris dalam menentukan model SLM yang paling optimal untuk skenario inferensi lokal berbasis dokumen.

Kata Kunci: *Small Language Models, Retrieval-Augmented Generation, Phi-3-mini, Gemma 2B, LLaMA 3.2, Ollama, LangChain, ChromaDB, Studi Komparatif, Inferensi Lokal.*

DAFTAR ISI

KATA PENGANTAR	2
ABSTRAK.....	3
BAB I.....	7
PENDAHULUAN	7
1.1 Latar Belakang.....	7
1.2 Rumusan Masalah.....	8
1.3 Tujuan Penelitian.....	8
1.4 Manfaat Penelitian.....	9
1.5 Batasan Penelitian.....	9
BAB II.....	10
TINJAUAN PUSTAKA	10
2.1 Small Language Models (SLMs).....	10
2.1.1 Definisi dan Karakteristik Fundamental	10
2.1.2 Microsoft Phi-3-mini	10
2.1.3 Google Gemma 2B	11
2.1.4 Meta LLaMA 3.2:1B.....	12
2.1.5 Perbandingan Ketiga Model (update tabel lama 2.1.4)	12
2.2 Retrieval-Augmented Generation (RAG).....	13
2.2.1 Konsep Dasar.....	13
2.2.2 Urgensi RAG pada SLM.....	14
2.3 Teknologi dan Framework Pendukung	14
2.3.1 Ollama	14
2.3.2 LangChain.....	15
2.3.3 ChromaDB	15
2.3.4 HuggingFace Sentence Transformers (all-MiniLM-L6-v2)	15
2.4 Kajian Penelitian Terdahulu.....	16

BAB III	17
METODOLOGI PENELITIAN	17
3.1 Jenis dan Pendekatan Penelitian.....	17
3.2 Arsitektur Sistem RAG	17
3.2.1 Ingestion Pipeline (Fase Pengindeksan)	17
3.2.2 Retrieval-Generation Pipeline (Fase Inferensi).....	18
3.3 Desain Prompt Engineering.....	19
3.4 Konfigurasi Parameter Model	19
3.5 Skenario Pengujian.....	20
3.6 Metrik Evaluasi	21
BAB IV	22
HASIL DAN ANALISIS.....	22
4.1 Deskripsi Lingkungan Pengujian	22
4.2 Fenomena Cold Start vs Warm Run	22
4.3 Hasil Pengukuran Time to First Token (TTFT)	23
4.4 Hasil Pengukuran Words per Second (WPS)	24
4.5 Konsumsi Memori RAM	25
4.6 Rekapitulasi Perbandingan Kuantitatif	26
4.7 Analisis Kualitatif Output RAG.....	26
4.8 Pembahasan: Implikasi Pemilihan Model	27
BAB V.....	29
ANALISIS ETIKA, BIAS, DAN KESIMPULAN	29
5.1 Refleksi Etis Penggunaan Small Language Models.....	29
5.2 Limitasi Teknis SLM dan Implikasi Etisnya	29
5.2.1 Halusinasi dan Risiko Misinformasi	29
5.2.2 Keterbatasan Penalaran Kompleks.....	30
5.3 Analisis Bias pada SLM	30

5.3.1 Bias Data Pelatihan.....	30
5.3.2 Bias Vendor dan Ekosistem	31
5.3.3 Bias Evaluasi	31
5.4 Rekomendasi Mitigasi	31
5.5 Kesimpulan.....	32
5.6 Saran Penelitian Lanjutan.....	33
DAFTAR PUSTAKA	35

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi kecerdasan buatan (*Artificial Intelligence/AI*), khususnya pada bidang *Natural Language Processing* (NLP), mengalami akselerasi yang belum pernah terjadi sebelumnya dalam satu dekade terakhir. Fenomena ini ditandai oleh kemunculan *Large Language Models* (LLMs) berparameter masif seperti GPT-4o milik OpenAI dan Gemini 1.5 Pro milik Google, yang mampu menghasilkan teks natural, menyelesaikan permasalahan kompleks, hingga mengotomatisasi berbagai tugas kognitif manusia. Kendati demikian, mayoritas LLM skala besar tersebut beroperasi secara eksklusif melalui infrastruktur *cloud* terpusat, sehingga menimbulkan serangkaian hambatan fundamental: ketergantungan pada koneksi internet yang stabil, biaya penggunaan API yang signifikan, serta kekhawatiran kritis terhadap keamanan dan privasi data pengguna yang dikirimkan ke server pihak ketiga.

Sebagai respons atas limitasi tersebut, tren riset dan industri kini bergeser secara progresif ke arah pengembangan *Small Language Models* (SLMs). SLM adalah kategori model bahasa yang dirancang dengan jumlah parameter lebih ringkas umumnya berkisar antara 0,5 hingga 7 miliar parameter namun dilatih menggunakan dataset berkualitas tinggi dan teknik distilasi pengetahuan (*knowledge distillation*) mutakhir, sehingga mampu mempertahankan kapabilitas penalaran dan pemahaman bahasa yang kompetitif. Tiga model yang menjadi subjek komparasi dalam penelitian ini mewakili tiga raksasa teknologi dunia: Microsoft Phi-3-mini (3,8 miliar parameter) yang unggul dalam penalaran logis, Google Gemma 2B (2 miliar parameter) yang menawarkan efisiensi memori superior, dan Meta LLaMA 3.2:1B (1 miliar parameter) yang merupakan model paling ringan namun berasal dari ekosistem LLaMA yang telah teruji secara luas. Ketiganya dapat dieksekusi langsung pada perangkat personal tanpa memerlukan GPU kelas *data center*, menjadikannya ideal untuk skenario *deployment* lokal yang menghargai privasi dan independensi infrastruktur.

Namun demikian, SLM memiliki limitasi inheren berupa kapasitas memori parametrik yang terbatas. Limitasi ini berimplikasi pada kecenderungan menghasilkan **halusinasi** (*hallucination*) kondisi di mana model memproduksi informasi yang tampak meyakinkan namun tidak faktual terutama ketika dihadapkan pada pertanyaan yang

memerlukan pengetahuan spesifik di luar cakupan data pelatihannya. Persoalan ini menjadi krusial apabila SLM diterapkan pada domain yang menuntut akurasi tinggi, seperti layanan akademis, analisis dokumen hukum, atau pengelolaan basis pengetahuan institusional.

Metodologi *Retrieval-Augmented Generation* (RAG) hadir sebagai solusi arsitektur yang tepat untuk mengatasi keterbatasan tersebut. RAG mengintegrasikan komponen *retrieval* berbasis kesamaan semantik dari basis data eksternal dengan kemampuan generasi teks model bahasa, memungkinkan model untuk "membuka referensi" secara *real-time* sebelum merumuskan jawaban. Implementasi RAG pada SLM secara lokal melalui ekosistem Ollama yang menyediakan antarmuka API standar untuk model seperti Phi-3 dan Gemma dikombinasikan dengan library orkestrasi LangChain dan ChromaDB sebagai *vector store*, membentuk arsitektur sistem AI lokal yang lengkap, efisien, dan dapat diaudit sepenuhnya.

Berlandaskan urgensi di atas, penelitian ini bertujuan membangun prototipe sistem RAG Chatbot berbasis SLM secara lokal menggunakan Ollama, sekaligus melakukan studi komparatif yang terstruktur dan berbasis data empiris terhadap performa model Phi-3-mini dan Gemma 2B. Hasil komparasi ini diharapkan menghasilkan panduan teknis dan ilmiah yang dapat dijadikan acuan dalam pemilihan model SLM yang paling sesuai untuk kebutuhan inferensi lokal berbasis dokumen.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, penelitian ini berfokus pada satu permasalahan utama: Bagaimana perbandingan efisiensi komputasi dan kualitas respons antara model Phi-3-mini, Gemma 2B, dan LLaMA 3.2:1B dalam sistem RAG Chatbot berbasis Ollama yang berjalan sepenuhnya secara lokal?

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah di atas, penelitian ini bertujuan untuk merancang dan mengimplementasikan sistem RAG Chatbot berbasis SLM yang berjalan sepenuhnya secara lokal menggunakan Ollama, serta membandingkan performa tiga model Phi-3-mini, Gemma 2B, dan LLaMA 3.2:1B secara empiris, baik dari sisi efisiensi komputasi (TTFT

dan WPS) maupun kualitas respons yang dihasilkan dalam konteks pipeline RAG berbasis dokumen.

1.4 Manfaat Penelitian

Penelitian ini diharapkan memberikan kontribusi pada dua dimensi utama:

- **Manfaat Teoritis:** Memberikan kontribusi pada khazanah literatur berbahasa Indonesia mengenai implementasi teknis RAG pada SLM lokal, khususnya perbandingan empiris Phi-3-mini versus Gemma 2B yang masih sangat terbatas dalam publikasi ilmiah domestik.
- **Manfaat Praktis:** Menghasilkan panduan teknis yang dapat langsung diaplikasikan oleh pengembang dan peneliti yang ingin membangun sistem chatbot berbasis dokumen secara lokal, tanpa bergantung pada layanan cloud berbayar, sekaligus menjamin privasi data pengguna secara penuh.

1.5 Batasan Penelitian

Untuk menjaga fokus dan validitas penelitian, ditetapkan batasan-batasan sebagai berikut:

1. Model yang dibandingkan dibatasi pada Phi-3-mini (3,8B, Ollama tag: phi3) dan Gemma 2B (Ollama tag: gemma:2b).
2. Seluruh proses komputasi berjalan secara lokal pada satu perangkat yang sama guna menjamin keadilan komparasi (*fair comparison*).
3. Evaluasi kualitas *output* dilakukan secara kualitatif-deskriptif oleh peneliti menggunakan rubrik yang telah ditetapkan, bukan melalui *benchmark* otomatis seperti RAGAS atau TruLens.
4. Dokumen *knowledge base* yang digunakan bersifat tematik dan terbatas pada domain yang telah ditentukan, sebagaimana dijabarkan pada Bab III.

BAB II

TINJAUAN PUSTAKA

2.1 Small Language Models (SLMs)

2.1.1 Definisi dan Karakteristik Fundamental

Small Language Models (SLMs) adalah kelas model bahasa berbasis arsitektur *transformer* yang memiliki jumlah parameter dalam rentang 1 hingga 7 miliar, berbeda secara fundamental dengan *Large Language Models* (LLMs) konvensional yang dapat mencapai ratusan miliar parameter. Meskipun berukuran lebih ringkas, SLM modern tidak sekadar versi "terkompresi" dari LLM, melainkan model yang dirancang dan dioptimalkan secara khusus melalui teknik pelatihan mutakhir seperti penggunaan dataset berkualitas tinggi (*highly-curated data*), distilasi pengetahuan (*knowledge distillation*), dan kuantisasi bobot (*weight quantization*) sehingga mampu menghasilkan performa yang kompetitif pada tugas-tugas spesifik.

Dalam konteks *deployment* lokal, SLM menawarkan tiga keunggulan struktural yang tidak dimiliki LLM berbasis *cloud*. Pertama, efisiensi komputasi, yakni kemampuan dieksekusi pada perangkat keras konsumen standar tanpa memerlukan klaster GPU kelas *data center*. Kedua, privasi data absolut, di mana seluruh proses inferensi berlangsung di dalam batas perangkat pengguna tanpa transmisi data keluar. Ketiga, latensi rendah, menghasilkan waktu respons yang lebih cepat karena tidak ada *overhead* transmisi jaringan ke server eksternal.

2.1.2 Microsoft Phi-3-mini

Phi-3-mini adalah model bahasa berparameter 3,8 miliar yang dikembangkan oleh Microsoft Research dan dirilis sebagai model *open-weights* pada tahun 2024. Model ini merupakan bagian dari keluarga Phi-3

yang filosofi pengembangannya berpusat pada satu hipotesis: kualitas data pelatihan lebih determinan daripada kuantitas parameter. Phi-3-mini dilatih menggunakan dataset yang terdiri dari buku pelajaran sintetis berkualitas tinggi, kode pemrograman, dan materi akademis terseleksi pendekatan yang terinspirasi dari cara manusia belajar melalui materi yang padat dan terstruktur, bukan sekadar volume bacaan yang besar.

Secara arsitektur, Phi-3-mini mengadopsi *transformer decoder-only* dengan dukungan *context window* hingga 128.000 token melalui mekanisme LongRoPE. Keunggulan signifikan model ini terletak pada kemampuan penalaran logis, matematika, dan pemahaman instruksi pemrograman yang melampaui ekspektasi untuk ukuran parameternya menjadikannya salah satu SLM paling kompetitif di kelas di bawah 5 miliar parameter.

2.1.3 Google Gemma 2B

Gemma 2B adalah model bahasa *open-weights* berparameter 2 miliar yang dikembangkan oleh Google DeepMind dan dirilis pada Februari 2024. Model ini dibangun menggunakan arsitektur dan teknik yang sama dengan yang mendasari model Gemini termasuk *Multi-Head Attention*, *RoPE Embeddings*, dan *GeGLU Activation* namun dikemas dalam ukuran yang jauh lebih ringkas dan dapat dijalankan pada perangkat konsumen biasa.

Gemma 2B mendukung *context window* sebesar 8.192 token, mencukupi untuk mayoritas kasus penggunaan RAG standar. Keunggulan utamanya adalah efisiensi memori yang luar biasa; dalam format kuantisasi Q4, model ini dapat berjalan pada RAM serendah 4GB. Dari sisi generasi bahasa, Gemma 2B menghasilkan teks yang natural dan fasih dengan gaya bahasa yang cenderung lebih konsisten dibandingkan model sekelasnya.

2.1.4 Meta LLaMA 3.2:1B

LLaMA 3.2:1B adalah model bahasa *open-weights* berparameter 1 miliar yang dikembangkan oleh Meta AI dan dirilis pada September 2024 sebagai bagian dari keluarga LLaMA 3.2. Model ini merupakan evolusi signifikan dari generasi sebelumnya, dirancang khusus untuk skenario *on-device deployment* dan inferensi lokal dengan konsumsi sumber daya yang sangat minimal. LLaMA 3.2:1B dilatih menggunakan teknik *pruning* dan *knowledge distillation* dari model LLaMA 3.1 yang lebih besar, memungkinkan model berukuran 1 miliar parameter ini mempertahankan kualitas pemahaman bahasa yang jauh melampaui ekspektasi ukurannya. Secara arsitektur, LLaMA 3.2:1B mengadopsi *Grouped Query Attention* (GQA) untuk efisiensi inferensi, *RoPE Positional Embeddings*, dan *SwiGLU Activation Function* ,komponen arsitektur yang sama dengan model LLaMA skala besar. Model ini mendukung *context window* sebesar 128.000 token, setara dengan Phi-3-mini, menjadikannya sangat kompetitif meski hanya memiliki 1 miliar parameter. Dalam ekosistem Ollama, model ini tersedia melalui tag llama3.2:1b dan dapat berjalan pada RAM serendah 2–3GB dalam format kuantisasi Q4, menjadikannya model paling ringan di antara tiga model yang dibandingkan dalam penelitian ini.

2.1.5 Perbandingan Ketiga Model (update tabel lama 2.1.4)

Aspek	Phi-3-mini	Gemma 2B	LLaMA 3.2:1B
Pengembang	Microsoft	Google DeepMind	Meta AI
Parameter	3,8 Miliar	2 Miliar	1 Miliar
Context Window	128k token	8k token	128k token

Aspek	Phi-3-mini	Gemma 2B	LLaMA 3.2:1B
Keunggulan	Penalaran logis	Efisiensi memori	Paling ringan & cepat
RAM (Q4)	~4–6 GB	~3–4 GB	~2–3 GB
Ollama Tag	phi3	gemma:2b	llama3.2:1b
Rilis	April 2024	Februari 2024	September 2024
Arsitektur	Decoder-only	Decoder-only	Decoder-only (GQA)

2.2 Retrieval-Augmented Generation (RAG)

2.2.1 Konsep Dasar

Retrieval-Augmented Generation (RAG) adalah paradigma arsitektur sistem AI yang diperkenalkan oleh Lewis et al. (2020) untuk mengatasi limitasi model bahasa yang hanya mengandalkan pengetahuan parametrik (*parametric memory*) yaitu pengetahuan yang tersimpan dalam bobot model dan bersifat statis sejak pelatihan selesai. RAG mengintegrasikan dua komponen utama: retriever, yang mengambil potongan dokumen relevan dari basis pengetahuan eksternal berdasarkan kesamaan semantik dengan kueri pengguna; dan generator, yakni model bahasa yang menghasilkan respons berdasarkan konteks yang disuplai oleh *retriever*.

Secara teknis, pipeline RAG terbagi menjadi dua fase utama. Fase Ingestion mencakup pemuatan dokumen, pemotongan teks (*chunking*), pembangkitan embedding, dan penyimpanan vektor ke dalam *vector database*. Fase Retrieval-Generation melibatkan konversi kueri pengguna menjadi *query vector*, pencarian *nearest-neighbor* semantik pada *vector database*, konstruksi *augmented prompt* yang menggabungkan konteks

dokumen dengan kueri asli, serta inferensi model bahasa untuk menghasilkan respons akhir.

2.2.2 Urgensi RAG pada SLM

Integrasi RAG pada SLM memiliki urgensi yang justru lebih kritis dibandingkan penerapannya pada LLM skala besar. Hal ini disebabkan oleh tiga limitasi inheren SLM yang secara langsung dapat dimitigasi melalui arsitektur RAG.

Pertama, mitigasi keterbatasan memori parametrik. Kapasitas SLM untuk menyimpan fakta dunia nyata berbanding lurus dengan jumlah parameternya. Phi-3-mini (3,8B) dan Gemma 2B memiliki kapasitas penyimpanan pengetahuan yang jauh di bawah LLM ratusan miliar parameter. RAG mengeliminasi keterbatasan ini dengan menyediakan "buku referensi terbuka" yang dapat diakses secara *real-time*.

Kedua, reduksi halusinasi. SLM memiliki probabilitas lebih tinggi untuk menghasilkan informasi yang tampak koherensi namun tidak faktual ketika ditanyai mengenai hal-hal spesifik di luar data pelatihannya. Dengan memaksa model mendasarkan jawabannya pada konteks dokumen yang eksplisit (*grounding*), RAG secara signifikan mereduksi tingkat halusinasi.

Ketiga, pembaruan pengetahuan tanpa *fine-tuning*. RAG memungkinkan pembaruan basis pengetahuan sistem secara instan hanya dengan menambahkan dokumen baru ke *vector store*, tanpa perlu melakukan *fine-tuning* ulang model yang membutuhkan waktu dan sumber daya komputasi besar.

2.3 Teknologi dan Framework Pendukung

2.3.1 Ollama

Ollama adalah *framework open-source* yang menyederhanakan pengelolaan dan eksekusi SLM secara lokal pada sistem operasi macOS, Linux, dan Windows. Ollama menyelesaikan tantangan kompleksitas konfigurasi yang sebelumnya menjadi hambatan utama inferensi model

lokal seperti instalasi driver CUDA, manajemen dependensi GGUF, dan optimasi kuantisasi dengan membungkus arsitektur model dalam format *Modelfile* yang terstandarisasi. Ollama menjalankan layanan API lokal pada endpoint `http://localhost:11434` yang kompatibel dengan antarmuka OpenAI API, memungkinkan integrasi *seamless* dengan library seperti LangChain.

2.3.2 LangChain

LangChain adalah *framework* Python *open-source* yang dirancang untuk menyederhanakan pengembangan aplikasi berbasis model bahasa melalui abstraksi komponen yang modular. Dalam konteks sistem RAG, LangChain menyediakan abstraksi untuk *Document Loaders*, *Text Splitters*, *Embedding Models*, *Vector Stores*, *Retrievers*, dan *Chains* yang menghubungkan seluruh komponen pipeline secara terstruktur. LangChain mendukung integrasi native dengan Ollama melalui kelas `OllamaLLM` dan `ChatOllama`, serta integrasi dengan ChromaDB melalui kelas `Chroma`.

2.3.3 ChromaDB

ChromaDB adalah *vector database open-source* yang dioptimalkan untuk penyimpanan dan pencarian *embedding* vektor berdimensi tinggi. ChromaDB mendukung mode *in-memory* (volatil) dan *persistent storage* berbasis DuckDB+Parquet, menjadikannya solusi yang fleksibel mulai dari tahap prototipe hingga sistem produksi skala kecil-menengah. Dalam sistem RAG, ChromaDB berfungsi sebagai repositori vektor yang menyimpan hasil *embedding* dokumen dan menyediakan antarmuka pencarian *nearest-neighbor* berbasis *cosine similarity*.

2.3.4 HuggingFace Sentence Transformers (all-MiniLM-L6-v2)

Model *embedding* all-MiniLM-L6-v2 dari HuggingFace Sentence Transformers adalah model *encoder* ringan yang menghasilkan representasi vektor berdimensi 384 untuk setiap input teks. Model ini merupakan hasil

distilasi dari arsitektur MiniLM-L12-v2, menawarkan keseimbangan optimal antara kualitas *embedding* dan kecepatan *encoding*. all-MiniLM-L6-v2 menjadi pilihan standar untuk sistem RAG skala lokal karena ukurannya yang kecil (~23MB), tidak memerlukan GPU untuk inferensi, dan performanya yang konsisten dalam pencarian semantik lintas domain.

2.4 Kajian Penelitian Terdahulu

Lewis et al. (2020) dalam makalah fondasi "*Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks*" membuktikan bahwa augmentasi *retrieval* secara signifikan meningkatkan akurasi model bahasa pada tugas berbasis pengetahuan spesifik. Gao et al. (2023) kemudian mengklasifikasikan evolusi RAG ke dalam tiga generasi *Naive RAG*, *Advanced RAG*, dan *Modular RAG* yang kerangka taksonominya digunakan sebagai acuan dalam penelitian ini.

Pada ranah implementasi lokal, penelitian yang dipublikasi di Jurnal Tekomin (2024) mendemonstrasikan kelayakan sistem RAG berbasis SLM lokal untuk evaluasi proposal tugas akhir mahasiswa, memvalidasi pendekatan yang diadopsi penelitian ini. Sementara itu, Infomedia Journal (2024) menunjukkan bahwa sistem RAG berbasis chatbot lokal mampu menangani keluhan pelanggan dengan tingkat relevansi jawaban yang tinggi meski menggunakan model berparameter kecil.

Namun demikian, penelitian komparatif yang secara khusus membandingkan Phi-3-mini versus Gemma 2B dalam konteks pipeline RAG lokal menggunakan metrik instrumentasi berbasis Python seperti TTFT dan WPS masih sangat terbatas dalam literatur berbahasa Indonesia mengonfirmasi novelty dan kontribusi dari penelitian ini.

BAB III

METODOLOGI PENELITIAN

3.1 Jenis dan Pendekatan Penelitian

Penelitian ini menggunakan pendekatan eksperimental-komparatif berbasis rekayasa sistem. Desain penelitian bersifat campuran (*mixed methods*): kuantitatif untuk pengukuran metrik performa komputasi seperti *Time to First Token* (TTFT) dan *Words per Second* (WPS), serta kualitatif-deskriptif untuk evaluasi kualitas output tekstual yang dihasilkan kedua model. Variabel bebas dalam penelitian ini adalah jenis model SLM yang digunakan Phi-3-mini versus Gemma 2B sedangkan variabel terikat mencakup kecepatan respons, konsumsi memori, relevansi jawaban, dan tingkat halusinasi.

3.2 Arsitektur Sistem RAG

Sistem RAG yang dibangun dalam penelitian ini terdiri dari dua fase utama yang bekerja secara sekuensial: **Ingestion Pipeline** untuk mempersiapkan basis pengetahuan, dan **Retrieval-Generation Pipeline** untuk melayani kueri pengguna secara real-time.

3.2.1 Ingestion Pipeline (Fase Pengindeksan)

Fase ini bertanggung jawab mengonversi dokumen mentah menjadi representasi vektor yang dapat dicari secara semantik. Tahapannya adalah sebagai berikut:

1. **Document Loading** Dokumen sumber dimuat menggunakan `DirectoryLoader` atau `PyPDFLoader` dari `LangChain` sesuai format file yang tersedia.
2. **Text Splitting (Chunking)** Dokumen dipotong menjadi fragmen teks menggunakan `RecursiveCharacterTextSplitter` dengan konfigurasi

chunk_size=500 karakter dan chunk_overlap=50 karakter. Tumpang tindih antar chunk diperlukan untuk menjaga kontinuitas konteks pada batas potongan.

3. **Embedding Generation** ,Setiap chunk dikonversi menjadi vektor numerik berdimensi 384 menggunakan model all-MiniLM-L6-v2 melalui HuggingFaceEmbeddings.
4. **Vector Storage** ,Vektor embedding beserta teks aslinya disimpan ke ChromaDB dalam mode *persistent storage*, sehingga basis data tidak perlu dibangun ulang pada setiap sesi.

3.2.2 Retrieval-Generation Pipeline (Fase Inferensi)

Fase ini aktif saat pengguna berinteraksi dengan chatbot. Alur prosesnya adalah:

1. **Query Embedding** Kueri teks dari pengguna dikodekan menjadi *query vector* menggunakan model embedding yang sama dengan fase ingestion.
2. **Semantic Retrieval** ChromaDB melakukan pencarian *cosine similarity* antara *query vector* dan seluruh vektor dalam database, mengembalikan k=3 chunk dokumen paling relevan.
3. **Prompt Augmentation** Chunk yang ditemukan digabungkan ke dalam prompt terstruktur bersama instruksi sistem dan kueri asli pengguna menggunakan PromptTemplate dari LangChain.
4. **LLM Inference Augmented prompt** dikirimkan ke model SLM melalui Ollama API lokal (<http://localhost:11434>) untuk menghasilkan respons akhir.
5. **Logging & Timing** Seluruh durasi proses dicatat menggunakan modul time Python untuk pengumpulan data metrik TTFT dan WPS.

3.3 Desain Prompt Engineering

Untuk memastikan determinisme output dan meminimalkan halusinasi, prompt dalam penelitian ini dirancang mengikuti tiga prinsip utama.

Pertama, system prompt yang membatasi secara eksplisit. Model diberikan instruksi sistem yang tegas untuk hanya menjawab berdasarkan konteks dokumen yang disediakan, dan secara eksplisit mengakui ketidaktahuan apabila konteks tidak mencukupi bukan mengarang jawaban.

Kedua, temperature deterministik sebesar 0,0 hingga 0,1 diterapkan pada kedua model untuk mengeliminasi variabilitas stokastik dalam proses pemilihan token, sehingga eksperimen dapat direproduksi.

Ketiga, template prompt terstruktur yang memisahkan secara jelas antara blok konteks dokumen, pertanyaan pengguna, dan instruksi format jawaban. Template yang digunakan adalah sebagai berikut:

Kamu adalah asisten AI yang menjawab pertanyaan HANYA berdasarkan konteks dokumen yang diberikan. Jika jawaban tidak terdapat dalam konteks, katakan "Informasi tersebut tidak tersedia dalam dokumen yang saya miliki." Jangan mengarang informasi di luar konteks.

Konteks:

{context}

Pertanyaan: {question}

Jawaban:

3.4 Konfigurasi Parameter Model

Seluruh parameter dikonfigurasi identik pada kedua model untuk menjamin keadilan komparasi (*fair comparison*), kecuali pada aspek yang memang berbeda secara inheren antar model.

Parameter	Phi-3-mini	Gemma 2B	LLaMA 3.2:1B
Ollama Tag	phi3	gemma:2b	llama3.2:1b
Jumlah Parameter	3,8 Miliar	2 Miliar	1 Miliar
Temperature	0,0 – 0,1	0,0 – 0,1	0,0 – 0,1
Top-K Retrieval	k = 3	k = 3	k = 3
Chunk Size	500 karakter	500 karakter	500 karakter
Chunk Overlap	50 karakter	50 karakter	50 karakter
Embedding Model	all-MiniLM-L6-v2	all-MiniLM-L6-v2	all-MiniLM-L6-v2
Context Window	128k token	8k token	128k token
Quantization	Q4_K_M	Q4_K_M	Q4_K_M
RAM Estimasi	~4–6 GB	~3–4 GB	~2–3 GB

3.5 Skenario Pengujian

Pengujian dilakukan menggunakan lima pertanyaan standar yang dirancang untuk menguji kemampuan berbeda dari masing-masing model:

1. **Recall faktual langsung** Pertanyaan yang jawabannya tersedia secara eksplisit dalam satu chunk dokumen.
2. **Inferensi multi-chunk** Pertanyaan yang memerlukan penggabungan informasi dari beberapa chunk berbeda.

3. **Pertanyaan di luar konteks** Pertanyaan yang jawabannya tidak tersedia dalam dokumen, untuk menguji kemampuan model menolak halusinasi.
4. **Pertanyaan multi-langkah** Pertanyaan yang memerlukan penalaran bertahap sebelum sampai pada jawaban akhir.
5. **Terminologi teknis spesifik** Pertanyaan dengan istilah domain khusus untuk menguji pemahaman kosakata teknis.

Setiap skenario dijalankan sebanyak **tiga kali** pada masing-masing model untuk memperoleh nilai rata-rata metrik yang lebih stabil dan representatif.

3.6 Metrik Evaluasi

a) Metrik Kuantitatif - Performa Komputasi

- **Time to First Token (TTFT)** Durasi dalam detik dari pengiriman prompt hingga token pertama respons diterima. Diukur menggunakan `time.time()` Python.
- **Words per Second (WPS)** Jumlah kata yang dihasilkan per detik, dihitung sebagai $\text{jumlah_kata_output} \div \text{total_durasi_generasi}$.
- **Konsumsi RAM** Memori sistem yang digunakan selama inferensi, dipantau menggunakan library `psutil`.

b) Metrik Kualitatif Kualitas Output

- **Relevansi** Sejauh mana jawaban menjawab pertanyaan yang diajukan berdasarkan konteks yang tersedia.
- **Faithfulness (Grounding)** Sejauh mana klaim dalam jawaban dapat ditelusuri kembali ke konteks dokumen yang disuplai, bukan dari pengetahuan bawaan model.
- **Tingkat Halusinasi** Ada atau tidaknya informasi dalam jawaban yang tidak dapat diverifikasi dari konteks dokumen.

BAB IV

HASIL DAN ANALISIS

4.1 Deskripsi Lingkungan Pengujian

Seluruh pengujian dilaksanakan pada lingkungan komputasi berbasis *cloud* menggunakan Google Colaboratory dengan spesifikasi runtime CPU standar. Ollama dijalankan di dalam sesi Colab, sementara seluruh proses inferensi model berlangsung tanpa akselerasi GPU eksternal. Kondisi ini mencerminkan skenario penggunaan nyata pada perangkat pribadi dengan sumber daya terbatas, sekaligus menjamin kesetaraan kondisi pengujian bagi ketiga model. Setiap model diuji menggunakan lima skenario pertanyaan (Q1–Q5), masing-masing dijalankan sebanyak tiga kali (*run*) untuk memperoleh data yang lebih stabil dan representatif.

4.2 Fenomena Cold Start vs Warm Run

Temuan paling signifikan dari keseluruhan data adalah adanya fenomena cold start yang sangat mencolok pada Run ke-1 untuk seluruh model. Pada iterasi pertama, Ollama perlu memuat bobot model (*model weights*) dari disk ke dalam memori RAM proses yang memakan waktu substansial dan tidak mencerminkan performa inferensi sesungguhnya. Setelah model termuat penuh (*warm state*), performa TTFT turun drastis pada Run ke-2 dan ke-3.

Model	TTFT Cold Start (Run 1)	TTFT Warm (Run 2 & 3)	Rasio Penurunan
Phi-3-mini	0,674 detik	0,090 detik	~7,5x lebih cepat
Gemma 2B	1,022 detik	0,514 detik	~2x lebih cepat

Model	TTFT Cold Start (Run 1)	TTFT Warm (Run 2 & 3)	Rasio Penurunan
LLaMA 3.2:1b	10,662 detik	0,553 detik	~19x lebih cepat

LLaMA 3.2:1b mencatatkan cold start paling ekstrem (10,66 detik) meski memiliki parameter paling sedikit hal ini diduga disebabkan oleh mekanisme inisialisasi *Grouped Query Attention* (GQA) yang memerlukan waktu setup lebih panjang pada lingkungan CPU tanpa akselerasi. Berdasarkan temuan ini, seluruh analisis perbandingan selanjutnya menggunakan data warm run (Run 2 dan Run 3) sebagai representasi performa inferensi yang sesungguhnya.

4.3 Hasil Pengukuran Time to First Token (TTFT)

TTFT mengukur responsivitas model seberapa cepat token pertama jawaban muncul setelah prompt dikirimkan. Nilai TTFT yang rendah sangat krusial dalam skenario chatbot interaktif.

Kode Soal	Phi-3-mini (detik)	Gemma 2B (detik)	LLaMA 3.2:1b (detik)
Q1	0,078	0,616	0,633
Q2	0,084	0,407	0,603
Q3	0,080	0,689	0,444
Q4	0,129	0,429	0,638
Q5	0,079	0,429	0,447
Rata-rata Warm	0,090 detik	0,514 detik	0,553 detik

Phi-3-mini mendominasi metrik TTFT secara mutlak unggul di seluruh lima skenario pertanyaan tanpa pengecualian. Dengan rata-rata

0,090 detik, Phi-3-mini hampir 6 kali lebih responsif dibandingkan Gemma 2B (0,514 detik) dan 6,1 kali lebih responsif dibandingkan LLaMA 3.2:1b (0,553 detik). Gemma 2B dan LLaMA 3.2:1b berada pada rentang performa yang hampir setara satu sama lain, dengan selisih hanya 0,039 detik.

Keunggulan TTFT Phi-3-mini ini sejalan dengan desain arsitekturalnya yang mengutamakan efisiensi inferensi pada perangkat lokal, sebagaimana dikonfirmasi dalam laporan teknis Microsoft (Abdin et al., 2024).

4.4 Hasil Pengukuran Words per Second (WPS)

WPS mengukur kecepatan generasi teks secara keseluruhan setelah token pertama muncul semakin tinggi nilai WPS, semakin cepat model menyelesaikan jawaban lengkapnya.

Kode Soal	Phi-3-mini	Gemma 2B	LLaMA 3.2:1b
Q1	24,09	28,57	11,52
Q2	21,71	24,85	46,07
Q3	21,83	11,34	15,46
Q4	19,33	16,59	12,12
Q5	21,80	29,01	33,94
Rata-rata Warm	21,75	22,07	23,82

LLaMA 3.2:1b mencatatkan WPS rata-rata tertinggi (23,82 kata/detik), diikuti Gemma 2B (22,07) dan Phi-3-mini (21,75). Namun perlu digarisbawahi bahwa selisih ketiganya sangat tipis hanya 2,07 kata/detik antara model tercepat dan terlambat sehingga secara perseptual perbedaan ini tidak terasa oleh pengguna akhir.

Temuan anomali yang sangat menarik adalah lonjakan WPS LLaMA 3.2:1b pada Q2 sebesar 46,07 kata/detik hampir dua kali lipat rata-ratanya sendiri. Setelah ditelaah, Q2 adalah pertanyaan inferensi multi-chunk yang

menghasilkan jawaban sangat singkat namun padat. LLaMA 3.2:1b sebagai model paling ringkas (1B parameter) mampu menghasilkan respons pendek dengan sangat cepat, namun kinerjanya menurun signifikan pada pertanyaan yang memerlukan elaborasi panjang (Q1: 11,52 WPS).

Sebaliknya, Phi-3-mini menunjukkan stabilitas WPS tertinggi dengan standar deviasi hanya 1,60 jauh lebih konsisten dibandingkan Gemma 2B (7,84) dan LLaMA 3.2:1b (14,76). Konsistensi ini merupakan keunggulan kritis dalam konteks sistem RAG yang menuntut prediktabilitas output.

4.5 Konsumsi Memori RAM

Data RAM pada seluruh sesi pengujian tercatat 0,0 GB pada semua model. Ini merupakan artefak teknis dari metode pengukuran: psutil hanya mengukur konsumsi RAM proses Python itu sendiri, sementara Ollama berjalan sebagai proses *daemon* terpisah sehingga konsumsi memorinya tidak tertangkap. Berdasarkan spesifikasi resmi dalam format kuantisasi Q4_K_M, estimasi konsumsi RAM ketiga model adalah:

Model	Parameter	Estimasi RAM (Q4_K_M)
Phi-3-mini	3,8B	~4,0 – 6,0 GB
Gemma 2B	2,0B	~2,5 – 3,5 GB
LLaMA 3.2:1b	1,0B	~1,5 – 2,5 GB

LLaMA 3.2:1b unggul signifikan pada dimensi efisiensi memori, menjadikannya pilihan ideal untuk perangkat dengan RAM di bawah 4GB.

4.6 Rekapitulasi Perbandingan Kuantitatif

Metrik	Phi-3-mini	Gemma 2B	LLaMA 3.2:1b	Pemenang
TTFT Warm rata-rata	0,090 det	0,514 det	0,553 det	✅ Phi-3-mini
WPS Warm rata-rata	21,75	22,07	23,82	✅ LLaMA 3.2:1b
Stabilitas WPS (stdev)	1,60	7,84	14,76	✅ Phi-3-mini
Cold Start	0,674 det	1,022 det	10,662 det	✅ Phi-3-mini
Estimasi RAM	~4–6 GB	~2,5–3,5 GB	~1,5–2,5 GB	✅ LLaMA 3.2:1b

4.7 Analisis Kualitatif Output RAG

1. **Q1 Recall Faktual Langsung:** Phi-3-mini menghasilkan jawaban ringkas dan presisi, langsung mengutip fakta dari konteks tanpa elaborasi berlebihan. Gemma 2B menghasilkan narasi lebih panjang dan natural namun sesekali menyertakan elaborasi di luar konteks. LLaMA 3.2:1b menghasilkan jawaban paling singkat kadang terlalu singkat hingga terasa kurang informatif.
2. **Q2 Inferensi Multi-Chunk:** Phi-3-mini unggul dalam menyusun inferensi logis dari beberapa sumber chunk. LLaMA 3.2:1b mencatatkan WPS tertinggi (46,07) pada skenario ini karena

responsnya sangat ringkas, namun kedalaman analisisnya paling terbatas di antara ketiga model.

3. **Q3 Pertanyaan di Luar Konteks:** Phi-3-mini paling konsisten menolak menjawab dan memberikan pernyataan sesuai instruksi sistem, menunjukkan *grounding* terbaik. Gemma 2B pada beberapa kasus mencoba menjawab menggunakan pengetahuan bawaannya. LLaMA 3.2:1b menunjukkan perilaku paling tidak konsisten kadang menolak, kadang menjawab sebagian.
4. **Q4 Pertanyaan Multi-Langkah:** Phi-3-mini menghasilkan jawaban bertahap paling terstruktur. Gemma 2B menghasilkan narasi yang mengalir namun kurang sistematis. LLaMA 3.2:1b cenderung melewati beberapa langkah penalaran.
5. **Q5 Terminologi Teknis:** Gemma 2B dan LLaMA 3.2:1b menunjukkan kecepatan generasi tertinggi pada skenario ini (29,01 dan 33,94 WPS), mengindikasikan bahwa kosakata teknis yang berulang lebih mudah diprediksi oleh model berparameter lebih kecil.

4.8 Pembahasan: Implikasi Pemilihan Model

Hasil pengujian mengungkap **tiga profil model yang berbeda** dengan keunggulan komparatif masing-masing:

1. Phi-3-mini adalah pilihan terbaik untuk skenario chatbot interaktif yang mengutamakan responsivitas dan akurasi. Keunggulan TTFT yang sangat signifikan (6x lebih cepat), stabilitas WPS tertinggi, dan kemampuan *grounding* terbaik menjadikannya model paling andal dalam konteks RAG berbasis dokumen.
2. Gemma 2B adalah pilihan terbaik untuk skenario yang mengutamakan kualitas bahasa. Meski kalah di TTFT, Gemma 2B menghasilkan teks paling natural dan fasih cocok untuk aplikasi yang memerlukan narasi panjang dan mengalir, seperti rangkuman dokumen atau penjelasan konseptual.

3. LLaMA 3.2:1b adalah pilihan terbaik untuk perangkat dengan sumber daya sangat terbatas. Dengan estimasi RAM hanya 1,5–2,5 GB dan WPS rata-rata tertinggi, LLaMA 3.2:1b ideal untuk *deployment* pada perangkat *edge* seperti Raspberry Pi atau laptop dengan RAM 4GB. Namun demikian, kualitas penalarannya paling terbatas di antara ketiganya, terutama pada pertanyaan kompleks.

BAB V

ANALISIS ETIKA, BIAS, DAN KESIMPULAN

5.1 Refleksi Etis Penggunaan Small Language Models

Pengembangan dan penerapan sistem kecerdasan buatan berbasis *Small Language Models* (SLMs) tidak dapat dilepaskan dari dimensi etika yang melekat pada setiap tahapan siklus hidupnya ,mulai dari proses pelatihan model, pemilihan data, hingga penerapan dalam sistem nyata yang berinteraksi langsung dengan pengguna. Penelitian ini mengidentifikasi empat dimensi etis utama yang relevan dengan sistem RAG berbasis SLM lokal.

5.2 Limitasi Teknis SLM dan Implikasi Etisnya

5.2.1 Halusinasi dan Risiko Misinformasi

Meskipun arsitektur RAG secara signifikan mereduksi tingkat halusinasi dibandingkan penggunaan SLM tanpa augmentasi retrieval, risiko ini tidak sepenuhnya dapat dieliminasi. Hasil pengujian kualitatif pada penelitian ini menunjukkan bahwa Gemma 2B dan LLaMA 3.2:1b masih menunjukkan kecenderungan menghasilkan informasi di luar konteks dokumen pada skenario Q3 (pertanyaan di luar konteks), meski telah diberikan instruksi sistem yang eksplisit untuk menolak menjawab.

Implikasi etis dari fenomena ini sangat kritis apabila sistem RAG berbasis SLM diterapkan pada domain sensitif seperti layanan kesehatan, konsultasi hukum, atau informasi akademis. Jawaban yang tampak meyakinkan namun tidak faktual dapat menyesatkan pengguna yang tidak memiliki kemampuan untuk memverifikasi kebenaran informasi secara mandiri. Oleh karena itu, sistem RAG berbasis SLM tidak direkomendasikan sebagai sumber otoritas tunggal pada domain yang memiliki konsekuensi tinggi terhadap keselamatan atau kesejahteraan

pengguna, melainkan harus selalu diposisikan sebagai alat bantu yang memerlukan verifikasi manusia.

5.2.2 Keterbatasan Penalaran Kompleks

SLM dengan parameter terbatas memiliki kapasitas penalaran yang secara inheren lebih rendah dibandingkan LLM skala besar. Penelitian ini mengkonfirmasi hal tersebut melalui hasil Q4 (pertanyaan multi-langkah), di mana LLaMA 3.2:1b secara konsisten melewati beberapa tahap penalaran yang diperlukan untuk menghasilkan jawaban yang lengkap. Penggunaan SLM untuk tugas-tugas yang memerlukan penalaran kausal mendalam, analisis kontrafaktual, atau inferensi multi-lapis berisiko menghasilkan output yang menyesatkan meski terlihat koheren secara gramatikal.

5.3 Analisis Bias pada SLM

5.3.1 Bias Data Pelatihan

Ketiga model yang dikaji dalam penelitian ini, Phi-3-mini, Gemma 2B, dan LLaMA 3.2:1b, dilatih secara dominan menggunakan korpus teks berbahasa Inggris. Implikasi langsungnya adalah ketiga model memiliki kemampuan pemahaman dan generasi bahasa Indonesia yang terbatas secara inheren. Dalam konteks RAG berbasis dokumen berbahasa Indonesia, model-model ini berpotensi menghasilkan:

- Kesalahan pemahaman nuansa bahasa (*false semantic interpretation*) pada frasa idiomatis atau istilah lokal
- Preferensi struktural terhadap pola kalimat gaya Barat yang tidak selalu sesuai dengan konvensi penulisan akademis Indonesia
- Underrepresentasi konteks budaya, hukum, dan sosial Indonesia dalam basis pengetahuan parametrik model

5.3.2 Bias Vendor dan Ekosistem

Penelitian ini menggunakan tiga model dari tiga vendor teknologi besar berbasis di Amerika Serikat dan ekosistem *open-source* yang didominasi komunitas global Barat (Microsoft, Google, Meta). Hal ini menciptakan potensi bias sistemik dalam perspektif yang direpresentasikan oleh model, nilai-nilai, asumsi budaya, dan kerangka konseptual yang tertanam dalam data pelatihan secara implisit mencerminkan perspektif dominan vendor tersebut. Tidak terdapat representasi dari model SLM yang dikembangkan oleh institusi atau komunitas Indonesia dalam studi komparatif ini, yang merupakan keterbatasan yang perlu diakui secara eksplisit.

5.3.3 Bias Evaluasi

Evaluasi kualitatif dalam penelitian ini dilakukan secara subjektif oleh peneliti menggunakan rubrik penilaian yang telah ditetapkan. Ketidadaan evaluator independen atau *benchmark* otomatis seperti RAGAS atau TruLens berpotensi menimbulkan bias konfirmasi (*confirmation bias*), di mana peneliti secara tidak sadar cenderung memberikan penilaian yang mengonfirmasi hipotesis awal. Keterbatasan ini diakui sebagai salah satu area yang perlu diperbaiki pada penelitian lanjutan.

5.4 Rekomendasi Mitigasi

Berdasarkan analisis etis dan bias di atas, penelitian ini merumuskan empat rekomendasi mitigasi:

1. Pertama, implementasi mekanisme disclaimer otomatis. Sistem RAG berbasis SLM sebaiknya dilengkapi dengan pesan peringatan otomatis yang menginformasikan pengguna bahwa jawaban yang diberikan bersumber dari dokumen yang diindeks dan mungkin mengandung ketidakakuratan, terutama pada domain sensitif.
2. Kedua, penerapan evaluasi otomatis berkelanjutan. Integrasi *framework* evaluasi seperti RAGAS pada pipeline produksi

memungkinkan pemantauan tingkat halusinasi dan relevansi secara real-time, sehingga degradasi kualitas model dapat dideteksi dan ditangani lebih awal.

3. Ketiga, diversifikasi model evaluasi. Penelitian lanjutan sebaiknya menyertakan model SLM dari ekosistem non-Barat ,seperti Qwen (Alibaba/Tiongkok) atau model yang dikembangkan komunitas Indonesia ,untuk memperoleh perspektif komparatif yang lebih berimbang dan relevan secara lokal.
4. Keempat, pengawasan manusia (*human-in-the-loop*). Untuk aplikasi pada domain kritis, sistem RAG berbasis SLM harus selalu diintegrasikan dengan mekanisme verifikasi oleh pakar manusia sebelum informasi yang dihasilkan dikomunikasikan kepada pengguna akhir.

5.5 Kesimpulan

Penelitian ini telah berhasil merancang dan mengimplementasikan sistem RAG Chatbot berbasis *Small Language Models* yang berjalan sepenuhnya secara lokal menggunakan Ollama, serta melakukan studi komparatif empiris terhadap tiga model ,Microsoft Phi-3-mini (3,8B), Google Gemma 2B (2B), dan Meta LLaMA 3.2:1b (1B) ,dengan hasil sebagai berikut.

Dari dimensi efisiensi komputasi, Phi-3-mini terbukti paling unggul dalam metrik *Time to First Token* (TTFT) dengan rata-rata 0,090 detik pada kondisi *warm run* ,hampir enam kali lebih cepat dibandingkan Gemma 2B (0,514 detik) dan LLaMA 3.2:1b (0,553 detik). Phi-3-mini juga mencatatkan stabilitas generasi teks (*WPS stability*) tertinggi dengan standar deviasi hanya 1,60, menjadikannya model paling konsisten dan prediktabel dalam konteks pipeline RAG.

Dari dimensi kecepatan generasi, LLaMA 3.2:1b mencatatkan rata-rata WPS tertinggi (23,82 kata/detik), meski dengan variabilitas yang sangat tinggi (standar deviasi 14,76) yang mengindikasikan performa tidak

konsisten antar skenario pertanyaan. Gemma 2B berada di posisi tengah pada kedua metrik kuantitatif.

Dari dimensi kualitas output, Phi-3-mini menunjukkan kemampuan *grounding* dan penolakan halusinasi terbaik, terutama pada skenario pertanyaan di luar konteks dokumen. Gemma 2B menghasilkan teks paling natural dan fasih. LLaMA 3.2:1b, meski paling efisien dari sisi memori, menunjukkan kedalaman penalaran paling terbatas pada pertanyaan kompleks.

Secara keseluruhan, Phi-3-mini direkomendasikan sebagai model utama untuk sistem RAG Chatbot lokal yang mengutamakan responsivitas, akurasi, dan konsistensi. LLaMA 3.2:1b direkomendasikan untuk skenario perangkat dengan keterbatasan RAM ekstrem. Gemma 2B direkomendasikan untuk aplikasi yang mengutamakan kualitas bahasa dan kelancaran narasi.

5.6 Saran Penelitian Lanjutan

Berdasarkan limitasi yang teridentifikasi, penelitian ini menyarankan beberapa arah pengembangan ke depan:

1. Pengukuran RAM yang akurat menggunakan pemantauan langsung terhadap proses Ollama melalui subprocess dan `ollama ps`, bukan melalui `psutil` yang hanya mengukur proses Python.
2. Evaluasi kuantitatif otomatis menggunakan *framework* RAGAS untuk mengukur *context precision*, *answer relevancy*, dan *faithfulness* secara objektif dan terukur.
3. Perluasan model komparasi dengan menyertakan model dari ekosistem Asia seperti Qwen2.5 (Alibaba) atau model komunitas Indonesia untuk perspektif yang lebih berimbang.
4. Pengujian pada domain spesifik seperti dokumen hukum, medis, atau akademis untuk mengukur ketahanan sistem RAG pada domain yang memerlukan akurasi tinggi.
5. Implementasi Advanced RAG seperti *HyDE* (*Hypothetical Document Embeddings*) atau *re-ranking* untuk meningkatkan

kualitas retrieval di luar pendekatan *Naive RAG* yang digunakan dalam penelitian ini.

DAFTAR PUSTAKA

- Abdin, M., Aneja, J., Awadalla, H., Awadallah, A., Awan, A. A., Bach, N., Bahree, A., Bakhtiari, A., Bao, J., Behl, H., Benhaim, A., Bilenko, M., Bjorck, J., Bubeck, S., Cai, M., Cai, Q., Chaudhary, V., Chen, D., Chen, D., ... Zhou, X. (2024). *Phi-3 Technical Report: A Highly Capable Language Model Locally on Your Phone* (arXiv:2404.14219). arXiv. <https://doi.org/10.48550/arXiv.2404.14219>
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2025). *Ragas: Automated Evaluation of Retrieval Augmented Generation* (arXiv:2309.15217). arXiv. <https://doi.org/10.48550/arXiv.2309.15217>
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, M., & Wang, H. (2024). *Retrieval-Augmented Generation for Large Language Models: A Survey* (arXiv:2312.10997). arXiv. <https://doi.org/10.48550/arXiv.2312.10997>
- Gunasekar, S., Zhang, Y., Aneja, J., Mendes, C. C. T., Giorno, A. D., Gopi, S., Javaheripi, M., Kauffmann, P., Rosa, G. de, Saarikivi, O., Salim, A., Shah, S., Behl, H. S., Wang, X., Bubeck, S., Eldan, R., Kalai, A. T., Lee, Y. T., & Li, Y. (2023). *Textbooks Are All You Need* (arXiv:2306.11644). arXiv. <https://doi.org/10.48550/arXiv.2306.11644>
- Hirschhoff, D., & Prebet, E. (2023). Using Pi-Calculus Names as Locks. *Electronic Proceedings in Theoretical Computer Science*, 387, 76–96. <https://doi.org/10.4204/EPTCS.387.7>
- Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2021). *LoRA: Low-Rank Adaptation of Large Language Models* (arXiv:2106.09685). arXiv. <https://doi.org/10.48550/arXiv.2106.09685>
- Izacard, G., & Grave, E. (2021). Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering. *Proceedings of the 16th Conference of the*

European Chapter of the Association for Computational Linguistics: Main Volume, 874–880. <https://doi.org/10.18653/v1/2021.eacl-main.74>

Johnson, J., Douze, M., & Jegou, H. (2021). Billion-Scale Similarity Search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. <https://doi.org/10.1109/TBDATA.2019.2921572>

Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W. (2020). Dense Passage Retrieval for Open-Domain Question Answering. *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, 6769–6781. <https://doi.org/10.18653/v1/2020.emnlp-main.550>

Pan, S., Luo, L., Wang, Y., Chen, C., Wang, J., & Wu, X. (2024). Unifying Large Language Models and Knowledge Graphs: A Roadmap. *IEEE Transactions on Knowledge and Data Engineering*, 36(7), 3580–3599. <https://doi.org/10.1109/TKDE.2024.3352100>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks. *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (EMNLP-IJCNLP)*, 3980–3990. <https://doi.org/10.18653/v1/D19-1410>

Team, G., Mesnard, T., Hardin, C., Dadashi, R., Bhupatiraju, S., Pathak, S., Sifre, L., Rivière, M., Kale, M. S., Love, J., Tafti, P., Hussenot, L., Sessa, P. G., Chowdhery, A., Roberts, A., Barua, A., Botev, A., Castro-Ros, A., Slone, A., ... Kenealy, K. (2024). *Gemma: Open Models Based on Gemini Research and Technology* (arXiv:2403.08295). arXiv. <https://doi.org/10.48550/arXiv.2403.08295>

Touvron, H., Martin, L., Stone, K., Albert, P., Almahairi, A., Babaei, Y., Bashlykov, N., Batra, S., Bhargava, P., Bhosale, S., Bikel, D., Blecher, L., Ferrer, C. C., Chen, M., Cucurull,

- G., Esiobu, D., Fernandes, J., Fu, J., Fu, W., ... Scialom, T. (2023). *Llama 2: Open Foundation and Fine-Tuned Chat Models* (arXiv:2307.09288). arXiv. <https://doi.org/10.48550/arXiv.2307.09288>
- Xiong, G., Jin, Q., Lu, Z., & Zhang, A. (2024). *Benchmarking Retrieval-Augmented Generation for Medicine* (arXiv:2402.13178). arXiv. <https://doi.org/10.48550/arXiv.2402.13178>
- Zhao, P., Zhang, H., Yu, Q., Wang, Z., Geng, Y., Fu, F., Yang, L., Zhang, W., Jiang, J., & Cui, B. (2024). *Retrieval-Augmented Generation for AI-Generated Content: A Survey* (arXiv:2402.19473). arXiv. <https://doi.org/10.48550/arXiv.2402.19473>
- Zhao, W. X., Zhou, K., Li, J., Tang, T., Wang, X., Hou, Y., Min, Y., Zhang, B., Zhang, J., Dong, Z., Du, Y., Yang, C., Chen, Y., Chen, Z., Jiang, J., Ren, R., Li, Y., Tang, X., Liu, Z., ... Wen, J.-R. (2026). *A Survey of Large Language Models* (arXiv:2303.18223). arXiv. <https://doi.org/10.48550/arXiv.2303.18223>
- Zhu, Y., Yuan, H., Wang, S., Liu, J., Liu, W., Deng, C., Chen, H., Liu, Z., Dou, Z., & Wen, J.-R. (2026). Large Language Models for Information Retrieval: A Survey. *ACM Transactions on Information Systems*, 44(1), 1–54. <https://doi.org/10.1145/3748304>